

---

## APLICAÇÃO DE REDES NEURAIS NA MODELAGEM PREDITIVA DA DENGUE

---

<sup>1</sup>BELLA, Matheus Henrique  
<sup>2</sup>TORRES, Giovanni Micheletti  
<sup>3</sup>CASTRO, Marcelo George de  
<sup>4</sup>NEGRETTO, Diego

Centro Universitário Hermínio Ometto – FHO, Araras – SP, Brasil

---

### Resumo

*Este trabalho visa desenvolver um modelo preditivo para antecipar surtos de dengue, utilizando redes neurais artificiais do tipo Multilayer Perceptron (MLP). A dengue tem aumentado significativamente no Brasil, influenciada por fatores climáticos como temperatura, umidade e precipitação. A modelagem preditiva, baseada em aprendizado de máquina, permite analisar esses fatores para prever a incidência da doença e apoiar a criação de políticas públicas mais eficazes.*

*O estudo envolve a coleta e análise de dados históricos de casos de dengue e variáveis climáticas, aplicando técnicas de aprendizado profundo para identificar padrões e gerar previsões. A arquitetura MLP foi escolhida por sua capacidade de modelar relações não lineares complexas, cruciais para entender a evolução da doença. O treinamento do modelo utiliza o algoritmo Backpropagation, e seu desempenho é avaliado por métricas como Erro Quadrático Médio (MSE) e Coeficiente de Determinação ( $R^2$ ).*

*Além da fundamentação teórica, o trabalho revisou estudos anteriores que aplicaram redes neurais na previsão de surtos de dengue e análise de fatores climáticos, demonstrando a importância dessa abordagem. Espera-se que os resultados incluam um modelo com alta precisão na previsão de surtos, contribuindo para otimizar a alocação de recursos de saúde e aprimorar estratégias de combate à doença.*

**Palavras chave:** Redes Neurais Artificiais (RNA), Multilayer Perceptron (MLP), Modelagem de dados.

---

<sup>1</sup>FHO|UNIARARAS. Aluno do Curso de Sistemas de Informação, Matheus Henrique Bella, matheus.bella07@alunos.fho.edu.br

<sup>2</sup>FHO|UNIARARAS. Aluno do Curso de Sistemas de Informação, Giovanni Micheletti Torres, matheus.bella07@alunos.fho.edu.br

<sup>3</sup>FHO|UNIARARAS. Professor do Curso de Sistemas de Informação, Marcelo George de Castro, marcelocastro@fho.edu.br

<sup>4</sup>FHO|UNIARARAS. Professor do Curso de Sistemas de Informação, Diego Negretto, diegonegretto@fho.edu.br

---

## 1 Introdução

### 1.1 Contextualização

O uso da análise de dados no combate a doenças como a dengue tem se mostrado uma ferramenta valiosa para prever casos e auxiliar os governos na preparação e realocação de recursos (CASTRO et al., 2022). Com o avanço das técnicas de aprendizado de máquina e a disponibilidade de dados históricos, a modelagem preditiva torna-se uma alternativa viável para antecipar cenários futuros (PHILIPS, 2020).

A dengue, em particular, destaca-se como uma das principais ameaças à saúde pública no Brasil, apresentando crescimento sem precedentes nos últimos anos. Um dos principais fatores que contribuem para os surtos de dengue no país é a mudança climática, que agrava ainda mais o cenário e dificulta o controle da doença (SIQUEIRA et al., 2018).

Os fatores climáticos desempenham um papel fundamental na proliferação do mosquito *Aedes aegypti*, influenciando diretamente a dinâmica de transmissão da doença. Entre os principais elementos estão a precipitação, a temperatura e a umidade. O aumento da precipitação e da umidade proporciona ambientes propícios para a formação de criadouros, enquanto o aumento da temperatura acelera o ciclo de vida do mosquito, reduzindo o tempo necessário para que os ovos se desenvolvam até a fase adulta (CEARÁ, 2024).

Diante do crescimento alarmante da dengue, a criação de ferramentas eficazes para combatê-la tornou-se urgente (MATTIOLI; ANDRADE; ESTEVEZ, 2017). Nesse contexto, este trabalho propõe a utilização de técnicas de análise de dados e aprendizado de máquina, com foco em redes neurais, para desenvolver um modelo preditivo capaz de antecipar surtos de dengue.

O modelo será alimentado por múltiplas fontes, como registros históricos de casos e condições climáticas. A combinação dessas informações permitirá identificar tendências que possam indicar a probabilidade de novos surtos.

### 1.2 Tema de Pesquisa

Este estudo propõe uma análise preditiva dos casos de dengue para o ano de 2024, buscando identificar as principais variáveis que podem influenciar o crescimento da doença. O foco principal é a aplicação de modelos de Redes Neurais, sendo utilizado, neste projeto, o tipo MLP (*Multilayer Perceptron*), uma rede neural artificial (ANN). Esse tipo de rede vem sendo aplicado com sucesso em diversas áreas, como previsão de séries temporais, reconhecimento de voz e reconhecimento de imagem (FERNANDES; PORTUGAL; NAVAUX, 1995).

O MLP foi escolhido devido à sua capacidade de identificar padrões nos dados e gerar previsões com maior grau de precisão. Além disso, sua habilidade de aprender relações não lineares complexas é essencial para modelar os diversos fatores que influenciam a evolução da doença, especialmente considerando a forte influência dos fatores climáticos.

---

### 1.3 Motivações e Justificativas

A escolha deste tema deve-se ao aumento crescente dos casos de dengue em todo o país, tornando-se uma grande preocupação. Diante disso, surge a necessidade de prever surtos da doença, possibilitando que as instituições governamentais tomem medidas antecipadas e desenvolvam estratégias mais eficazes. Isso permite otimizar a alocação de recursos e reduzir o impacto da dengue na população.

Atualmente, a maioria dos estudos sobre previsões epidemiológicas utiliza métodos estatísticos; este trabalho investiga o uso de redes neurais não-lineares para ganho de precisão.

Além disso, este estudo busca contribuir para o aperfeiçoamento das técnicas de análise de dados aplicadas à saúde pública, demonstrando a eficiência das redes neurais do tipo MLP.

### 1.4 Objetivos

#### 1.4.1 Objetivo Geral

Desenvolver e avaliar o modelo de análise preditiva com Redes neurais artificiais, *Multilayer Perceptron*, utilizando das principais variáveis que influenciam a doença, comparando os resultados previstos com os concretos

#### 1.4.2 Objetivos Específicos

- Coletar e organizar bases de dados sobre a incidência de dengue no período determinado;
- Aplicar modelos de aprendizado de máquina, com ênfase em redes neurais do tipo MLP (*Multilayer Perceptron*);
- Comparar diferentes abordagens preditivas para avaliar a acurácia e confiabilidade dos modelos;
- Avaliar a performance preditiva por meio de métricas padronizadas (MSE,  $R^2$ , etc.);
- Identificar padrões e tendências nos dados que possam auxiliar na formulação de políticas públicas para o combate à dengue.

## 2 Revisão Bibliográfica

### 2.1 Fundamentação Teórica e Técnica

As Redes Neurais Artificiais (RNA) são modelos computacionais inspirados no funcionamento dos neurônios biológicos e amplamente utilizadas em tarefas de reconhecimento de padrões, previsão de séries temporais e classificação de dados. Esses modelos são capazes de aprender padrões complexos a partir de dados (GRÜBLER, 2018) e podem ser aplicados na análise epidemiológica da dengue.

A arquitetura MLP é uma das mais utilizadas para problemas de classificação e regressão. Conforme mostrado na Figura 1 que se encontra Apêndice A, ela consiste de três principais camadas: a camada de entrada, que recebe os dados brutos

correspondentes às variáveis climáticas e epidemiológicas, as camadas ocultas, responsáveis por realizar transformações matemáticas sobre os dados utilizando pesos e funções de ativação para extrair padrões complexos e a camada de saída, que gera as previsões (GRÜBLER, 2018), podendo indicar o nível de risco de incidência de dengue.

### 2.1.1 Funções de ativação

As funções de ativação introduzem não linearidade ao modelo, permitindo a aprendizagem de padrões complexos (LEITE, 2018). Uma das mais utilizadas é a ReLU (*Rectified Linear Unit*), definida pela seguinte função:

$$f(x) = \max(0, x)$$

Essa função retorna zero para valores negativos e mantém valores positivos inalterados, promovendo uma convergência mais rápida durante o treinamento. A ReLU é amplamente usada por sua simplicidade computacional e por reduzir o problema do desaparecimento do gradiente, comum em funções sigmóides.

### 2.1.2 Métricas de Erro

A avaliação da qualidade das previsões realizadas pelo modelo é feita por meio de métricas de erro. As duas mais comuns em regressão são:

- Erro Quadrático Médio (MSE - Mean Squared Error): mede a média dos quadrados das diferenças entre os valores previstos e os valores reais. Sua fórmula é:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Onde  $y_i$  é o valor real,  $\hat{y}_i$  é o valor previsto e  $n$  é o número total de observações. Essa métrica penaliza erros grandes de forma mais severa.

- Erro Absoluto Médio (MAE - Mean Absolute Error): mede a média dos valores absolutos das diferenças entre os valores reais e previstos. Sua fórmula é:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

O MAE é menos sensível a outliers do que o MSE e fornece uma interpretação mais direta dos erros em unidades da variável prevista.

---

### 2.1.3 Estratégias de Treinamento

Ao treinar redes neurais, é crucial empregar métodos que previnam o overfitting, situação onde o modelo memoriza os dados de treino e falha ao lidar com dados inéditos. Há duas formas eficazes de mitigar isso:

- **Early Stopping:** interrompe automaticamente o treinamento quando a performance do modelo nos dados de validação para de melhorar após um certo número de épocas consecutivas (patience). Isso evita que o modelo continue aprendendo ruídos dos dados e degrade sua capacidade de generalização;
- **ModelCheckpoint:** permite salvar automaticamente o modelo durante o treinamento, geralmente armazenando a versão que obteve o melhor desempenho em um conjunto de validação. Dessa forma, mesmo que o modelo continue treinando e sofra degradação, a melhor versão já estará salva.

A relação entre fatores climáticos e a propagação da dengue é um ponto essencial do estudo. A precipitação influencia diretamente na proliferação do *Aedes aegypti*, criando criadouros para o mosquito. A temperatura média afeta o ciclo de vida do mosquito, acelerando sua reprodução e a transmissão do vírus. Já a umidade relativa desempenha um papel crucial na sobrevivência do mosquito, aumentando o risco de transmissão da doença.

A utilização de redes neurais artificiais para analisar a influência das variáveis climáticas na incidência de dengue proporciona uma abordagem promissora para previsão e monitoramento epidemiológico. A implementação de métodos adequados de treinamento e avaliação do modelo é essencial para garantir previsões precisas e eficientes, contribuindo para a formulação de estratégias de combate à doença.

## 2.2 Trabalhos Relacionados

Pode-se citar alguns exemplos de trabalhos relacionados para o desenvolvimento de aplicação para redes neurais:

O trabalho de Caíque Quaresma Silva (2019) abordava a teoria das redes neurais e sobre o treinamento da rede neural MLP (*Multilayer Perceptron*) e CNN (*Convulational Neural Network*).

O estudo de Eduardo Soares Leite (2023) analisou a relação entre clima e casos de dengue em Uberlândia, mostrando que temperaturas mínimas acima de 18 °C, médias entre 26 °C e 28 °C, e umidade acima de 70% favoreceram o aumento dos casos. Já temperaturas máximas acima de 30 °C reduziram os registros. Além disso, cada região da cidade apresentou padrões climáticos distintos que influenciaram a incidência da doença. Os resultados podem apoiar ações para controlar surtos.

A dissertação de Letícia Fernandes dos Reis (2023) propõe o uso de uma rede neural convolucional (CNN), especificamente a YOLOv8, para identificar piscinas — potenciais criadouros do mosquito da dengue — em imagens de sensoriamento remoto. Após

preparar e treinar o modelo com dados anotados, o desempenho foi avaliado, destacando a eficácia da abordagem na detecção automática desses focos, contribuindo para o combate à doença.

### 3 Metodologia

#### 3.1 Procedimentos Metodológicos

##### 3.1.1 Coleta de dados

A coleta de dados foi realizada a partir de fontes oficiais e confiáveis: informações climáticas do Instituto Nacional de Meteorologia (INMET), dados de temperatura provenientes do Centro de Previsão de Tempo e Estudos Climáticos (CPTEC), e registros de casos e óbitos relacionados à dengue obtidos do DATASUS (Departamento de Informática do SUS).

##### 3.1.2 Tratamento e Limpeza dos Dados

Os dados coletados foram submetidos a um processo de ETL (Extract, Transform, Load), que incluiu:

- Remoção de inconsistências, como valores ausentes e duplicados;
- Normalização das unidades de medida;
- Criação de novas variáveis derivadas, como médias móveis de temperatura.

Conforme ilustrado na Figura 2 que se encontra Apêndice B, o fluxo de trabalho demonstra as etapas do ETL e como os dados são tratados antes de serem utilizados nas análises.

##### 3.1.3 Ferramentas e Tecnologias

O estudo faz uso das seguintes ferramentas:

- **Linguagens e bibliotecas:** Python com bibliotecas como Pandas, Numpy, Matplotlib, Scikit-Learn para análise de dados; TensorFlow e Keras para desenvolvimento e treinamento do modelo preditivo;
- **Funções de ativação:** ReLU para camadas ocultas (evita gradientes nulos) e função linear para a camada de saída (prevê valores contínuos);
- **Métricas de erro:** Erro Quadrático Médio (MSE) para penalizar grandes desvios e Erro Absoluto Médio (MAE) para tratar erros de forma uniforme;
- **Armazenamento:** SQL, para consulta e manipulação de dados estruturados.

Conforme ilustrado na Figura 3 que se encontra Apêndice C, apresenta-se a estrutura do banco de dados utilizado, com registros da dengue entre os anos de 2013 e 2024.

### 3.1.4 Análise de Dados

A análise dos dados será conduzida em três etapas principais:

- **Análise exploratória:** Visa compreender os dados, identificar padrões e relações entre variáveis;
- **Análise descritiva:** Aplica estatísticas básicas (como médias, desvios e distribuições) para sumarizar os dados;
- **Análise preditiva:** Foca na construção de modelos capazes de prever casos e óbitos por dengue com base em dados históricos (2014 a 2023).

### 3.2 Validação e Confiabilidade

Para garantir a confiabilidade e validade dos resultados, as seguintes práticas foram adotadas:

- Comparação com relatórios e estudos oficiais divulgados por órgãos de saúde;
- Utilização de *Early Stopping* para evitar overfitting durante o treinamento;
- Divisão do conjunto de dados em treino (80%) e teste (20%);
- Validação cruzada para garantir a robustez estatística dos resultados obtidos;
- Cada configuração da rede neural será executada 25 vezes, com o objetivo de garantir resultados mais confiáveis e estatisticamente robustos. Essa repetição permite avaliar o impacto da aleatoriedade na inicialização dos pesos, comum em modelos de aprendizado profundo. Ao realizar múltiplas execuções, é possível obter uma média de desempenho mais estável, reduzir a influência de variações pontuais e verificar a consistência dos resultados. Essa abordagem reforça a confiabilidade da análise e melhora a capacidade de generalização do modelo;
- Para garantir a confiabilidade dos resultados, foi utilizada a métrica MAE (*Mean Absolute Error*) — Erro Absoluto Médio, para avaliar o desempenho da rede neural;
- Camadas: 256, 128, 64;
- Dropout: 0.2, 0.2, 0.2;
- L2: 1e-4, 1e-4, 1e-4;
- Learning\_rate: 0.0005;
- Epochs: 150;
- Batch\_size: 32;
- Early Stopping :
  - monitor: val\_loss;
  - patience: 15;
  - restore\_best\_weights = True;
  - verbose = 1;
  - min\_delta = 0.001;
- ModelCheckpoint -
  - 'Dados/melhor\_modelo\_mensal.keras';
  - monitor = 'val\_loss';
  - save\_best\_only = True;
  - verbose = 1.



---

### 3.3 Ambiente Computacional

Para a execução dos experimentos, foi utilizado o seguinte ambiente computacional:

- **Processador:** AMD Ryzen 7 5700U;
- **Memória RAM:** 8GB DDR4;
- **Sistema Operacional:** Windows 11;
- **Placa de Vídeo (GPU):** Placa gráfica AMD Radeon™;
- **Armazenamento:** 256GB SSD;
- **Ambiente de Desenvolvimento:** Visual Studio Code e MySQL Workbench;
- **Versões de ferramentas principais:**
  - Python - 3.9.7;
  - tensorflow-cpu - 2.13.0;
  - keras - 2.13.1;
  - pandas - 2.2.3;
  - MySQL Workbench - 8.0.

Devido à limitação da memória RAM durante o desenvolvimento do código, foi necessário utilizar exclusivamente a memória virtual (swap) alocada do SSD, resultando em um uso contínuo de 19 GB. Essa abordagem foi adotada para contornar a restrição de capacidade da RAM.

### 3.4 Aplicação da Rede Neural

Para a construção e aplicação da rede neural, foram seguidas as etapas descritas abaixo:

#### 3.4.1 Carregamento e Pré-processamento dos Dados

- **Carregamento dos Dados:**
  - A primeira fase envolve a importação de dados de um banco de dados MySQL através do uso de SQLAlchemy e Pandas. A função `carregar_dados()` estabelece uma conexão com o banco de dados e executa uma consulta para obter os dados históricos de dengue. Caso a consulta não retorne dados ou ocorra um erro, o processo é interrompido, e uma mensagem de erro é registrada.
- **Pré-Processamento dos Dados:**
  - **Seleção das Colunas:** A função `processar_dados()` seleciona as colunas relevantes, incluindo dados sobre o estado, mês, ano, temperatura, precipitação, casos e mortes;
  - **Codificação de Variáveis Categóricas:** A função `pd.get_dummies()` converte as variáveis Estado e Mês em variáveis dummy, tornando-as em variáveis categóricas numéricas;
  - **Escalonamento de Dados:** As variáveis preditoras (X) são escaladas utilizando o `StandardScaler` para garantir que todas as variáveis possuam a mesma magnitude, enquanto os valores de resposta (y) são escalados com o `MinMaxScaler`.



### 3.4.2 Construção e Treinamento do Modelo Preditivo

- **Criação da Rede Neural:**
  - A função `criar_e_treinar_modelo()` tem a tarefa de montar e treinar a rede neural usando as bibliotecas Keras e TensorFlow. O modelo é formado por três camadas ocultas densas, que usam a função de ativação ReLU e têm regularização L2. Além disso, ele inclui camadas de dropout para ajudar a prevenir o overfitting.
- **Estratégias de Treinamento:**
  - **Early Stopping:** Para evitar o overfitting, é utilizado o EarlyStopping, que interrompe o treinamento caso a perda de validação não melhore após as épocas inseridas;
  - **ModelCheckpoint:** O melhor modelo (baseado na menor perda de validação) é salvo durante o treinamento.
- **Treinamento:**
  - O modelo é treinado utilizando um número pré-definido de iterações (épocas), processando os dados em lotes de tamanho fixo durante cada atualização dos pesos. A divisão dos dados segue uma proporção estabelecida, onde a maior parte é destinada ao treinamento e uma parcela menor é separada para avaliação em tempo real do desempenho (validação).

### 3.4.3 Previsão e Avaliação

- **Previsão:**
  - Depois do treinamento, o modelo foi desenvolvido para fazer previsões mensais de casos e mortes de dengue ao longo de 2024. A função `fazer_previsoes_mensais()` percorre todos os estados e meses, cria as entradas necessárias para cada combinação, normaliza os dados e realiza as previsões de casos e óbitos;
- **Gráfico de Perda:**
  - Para avaliar o desempenho do modelo, o gráfico de perda (MSE) é gerado ao longo das épocas, permitindo a visualização da convergência do modelo.

A Figura 4 que se encontra Apêndice D apresenta um diagrama de fluxo que resume graficamente as etapas na construção do modelo de rede neural aplicado à previsão de casos e mortes por dengue. Cada etapa descrita nos tópicos anteriores (carregamento, pré-processamento, construção do modelo, treinamento e previsão/avaliação) é representada visualmente para facilitar a compreensão do processo como um todo.

---

## 4 Resultados

### 4.1 Resultados Esperados

Com a implementação do modelo preditivo baseado em Redes Neurais Artificiais (RNA) do tipo *Multilayer Perceptron* (MLP), espera-se alcançar os seguintes resultados:

- Modelo Preditivo Eficiente
  - Desenvolvimento de um modelo capaz de prever surtos de dengue com base em variáveis climáticas (temperatura, precipitação) e dados epidemiológicos históricos (casos, mortes), sendo esses dados de 2014 a 2023;
  - Alta precisão nas previsões, validada por métricas como Erro Quadrático Médio (MSE), indicando uma boa generalização do modelo.
- Validação e Robustez
  - Mitigação de *overfitting* e *underfitting* por meio de técnicas como *Dropout*, *Early Stopping* e validação cruzada, garantindo confiabilidade nas previsões;
  - Testes com dados de diferentes regiões para verificar a adaptabilidade do modelo a contextos variados.

### 4.2 Resultados Parciais

Com a implementação do sistema de previsão utilizando redes neurais, foi possível alcançar resultados parciais.

#### 4.2.1 Previsão Gerada

As previsões são geradas para cada mês de Bahia, São Paulo, Rio Grande do Sul, Rio de Janeiro, com base nos dados históricos, climáticos e epidemiológicos processados pelo modelo. As previsões completas foram salvas de forma automática no arquivo `previsões_mensais.csv`, conforme ilustrado na Figura 6 que se encontra no Apêndice E.

#### 4.2.2 Métricas de Desempenho

A Figura 7 que se encontra no Apêndice F apresenta o comportamento do Erro Quadrático Médio (MSE) tanto no conjunto de validação (linhas vermelhas) quanto no de treinamento (linhas azuis) ao longo das épocas, em 25 execuções distintas da rede neural com a mesma configuração.

O gráfico permite observar:

- A convergência dos modelos ao longo do tempo, sendo que as curvas de MSE tendem a diminuir, demonstrando aprendizado;

- A época destacada com a linha vertical verde (época 139) representa o ponto em que foi alcançado o menor valor de `val_loss` (erro de validação), considerado o melhor desempenho da rede com base no critério de parada antecipada (*early stopping*);
- O ponto amarelo com borda preta marca a combinação com menor `val_loss`, indicando a execução mais eficaz na generalização. Essa visualização facilita a avaliação da estabilidade do treinamento, mostrando se os modelos convergem de forma consistente ou se houve grande variabilidade entre execuções. No caso em questão, percebe-se que a maioria das execuções teve um comportamento estável, com diferenças pequenas entre treino e validação, evidenciando boa capacidade de generalização do modelo.

Durante o processo de treinamento, o melhor desempenho do modelo foi registrado na época 139 da 7ª execução, apresentando os seguintes resultados:

- **Loss (treinamento):** 0,011131;
- **Val\_loss (validação):** 0,014657;
- **MAE (treinamento):** 0,025198;
- **Val\_MAE (validação):** 0,026847.

Esses valores indicam que o modelo alcançou uma boa capacidade de generalização, mantendo o erro absoluto médio de validação próximo ao de treinamento, com diferença mínima entre os conjuntos, o que reforça sua estabilidade e robustez.

## 5 Considerações Finais

A presente pesquisa demonstra o potencial das redes neurais artificiais, em especial o modelo MLP (Perceptron Multicamadas), na modelagem preditiva de casos de dengue com base em dados climáticos. Os experimentos realizados evidenciaram que técnicas de aprendizado de máquina podem identificar padrões não triviais entre variáveis meteorológicas e a incidência da doença, contribuindo para estratégias de prevenção mais eficazes.

Para dar continuidade, recomenda-se o aprofundamento na calibração do modelo, com ajustes mais refinados em parâmetros como número de camadas, quantidade de neurônios, taxa de aprendizado e critérios de regularização. Essa calibragem pode ser conduzida por meio de testes controlados e comparativos, avaliando o impacto de diferentes configurações na performance do modelo.

Além disso, a inclusão de novas variáveis, como densidade populacional, histórico de surtos e dados de mobilidade urbana, pode aumentar a sensibilidade do modelo em cenários reais. Também é indicada a experimentação com outras arquiteturas de redes neurais, como LSTM, e a integração dos resultados em plataformas visuais e interativas, que ampliem a utilidade prática da solução para gestores da saúde pública.

---

**ALAKE, Richmond.** Explicação das funções de perda no aprendizado de máquina. 2024. Disponível em: <https://www.datacamp.com/pt/tutorial/loss-function-in-machine-learning>. Acesso em: 19 maio 2025.

**ALI, Moez.** Introdução às funções de ativação em redes neurais. 2024. Disponível em: <https://www.datacamp.com/pt/tutorial/introduction-to-activation-functions-in-neural-networks>. Acesso em: 19 maio 2025.

**CASTRO, Angélica F. et al.** Utilização da linguagem Python na análise de dados de dengue em Recife, capital do estado de Pernambuco, Nordeste do Brasil e definição de linha de tendência usando Machine Learning. 2022. Disponível em: [https://www.researchgate.net/publication/361989988\\_Utilizacao\\_da\\_linguagem\\_Python\\_na\\_analise\\_de\\_dados\\_de\\_dengue\\_em\\_Recife\\_capital\\_do\\_estado\\_de\\_Pernambuco\\_Nordeste\\_do\\_Brasil\\_e\\_definicao\\_de\\_linha\\_de\\_tendencia\\_usando\\_Machine\\_Learning\\_Use\\_of\\_Python\\_language](https://www.researchgate.net/publication/361989988_Utilizacao_da_linguagem_Python_na_analise_de_dados_de_dengue_em_Recife_capital_do_estado_de_Pernambuco_Nordeste_do_Brasil_e_definicao_de_linha_de_tendencia_usando_Machine_Learning_Use_of_Python_language). Acesso em: 10 mar. 2025.

**CEARÁ.** Secretaria da Saúde. Calor e período chuvoso aumentam riscos de proliferação de mosquito transmissor da dengue; conheça os sintomas e saiba como se proteger. 2024. Disponível em: <https://www.saude.ce.gov.br/2024/02/26/calor-periodo-chuvoso-riscos-proliferacao-mosquito-transmissor-dengue-sintomas/>. Acesso em: 20 mar. 2025.

**CENTRO DE PREVISÃO DE TEMPO E ESTUDOS CLIMÁTICOS.** Monitoramento América do Sul. Disponível em: <https://clima.cptec.inpe.br/monitoramentobrasil/pt>. Acesso em: 25 mar. 2025.

**FERNANDES, Luiz Gustavo L.; PORTUGAL, Marcelo Savino; NAVAUX, Philippe O. A.** Previsão de Séries de Tempo: Redes Neurais Artificiais e Modelos Estruturais. 1995. Disponível em: <https://gmap.pucrs.br/files/publications/articles/5afca684be812ed8e2a901173d20e6b6.pdf>. Acesso em: 20 fev. 2025.

**GRÜBLER, Murillo (org.).** *Stories Stats aibrazil Home About Entendendo o funcionamento de uma Rede Neural Artificial*. 2018. Disponível em: <https://medium.com/brasil-ai/entendendo-o-funcionamento-de-uma-rede-neural-artificial-4463fcf44dd0>. Acesso em: 18 mar. 2025.

**LEITE, Eduardo Soares.** Análise temporal da relação entre dengue e variáveis climáticas na cidade de Uberlândia – MG. 2023. 101 f. Monografia (Especialização) - Curso de Pós-Graduação em Geografia: Análise, Planejamento e Gestão Ambiental, Universidade Federal de Uberlândia, Uberlândia, 2023. Disponível em: <https://repositorio.ufu.br/bitstream/123456789/37954/3/An%C3%A1liseTemporalRela%C3%A7%C3%A3o.pdf>. Acesso em: 20 mar. 2025.

---

**LEITE, Tiago M.** Redes Neurais, Perceptron Multicamadas e o Algoritmo

Backpropagation. 2018. Disponível em:

<https://medium.com/ensina-ai/redes-neurais-perceptron-multicamadas-e-o-algoritmo-back-propagation-eaf89778f5b8>. Acesso em: 18 mar. 2025.

**MATTIOLI, Fernando Eduardo Rezende; ANDRADE, Rogério Bernardes; ESTEVEZ, Emanuel Tobias.** Predição de casos de dengue utilizando redes neurais artificiais. *Jetma*, Uberaba, p. 8-12, jan. 2017.

**MINISTÉRIO DA SAÚDE/SVSA.** Dengue - Notificações registradas no Sistema de Informação de Agravos de Notificação - Brasil. Disponível em:

[https://tabnet.saude.sp.gov.br/deftohtm.exe?tabnet/sim\\_ccd.def](https://tabnet.saude.sp.gov.br/deftohtm.exe?tabnet/sim_ccd.def). Acesso em: 25 mar. 2025.

**MINISTÉRIO DA SAÚDE/SVSA.** Dengue - Notificações registradas no Sistema de Informação de Agravos de Notificação - Brasil. 2024. Disponível em:

<http://tabnet.datasus.gov.br/cgi/deftohtm.exe?sinanet/cnv/denguebbr.def>. Acesso em: 25 mar. 2025.

**PHILIPS.** Análise preditiva em saúde: três exemplos do mundo real. 2020. Disponível em:

<https://www.philips.com.br/a-w/about/news/archive/standard/article/2020/20200604-predictive-analytics-in-healthcare-three-real-world-examples.html>. Acesso em: 19 mar. 2025.

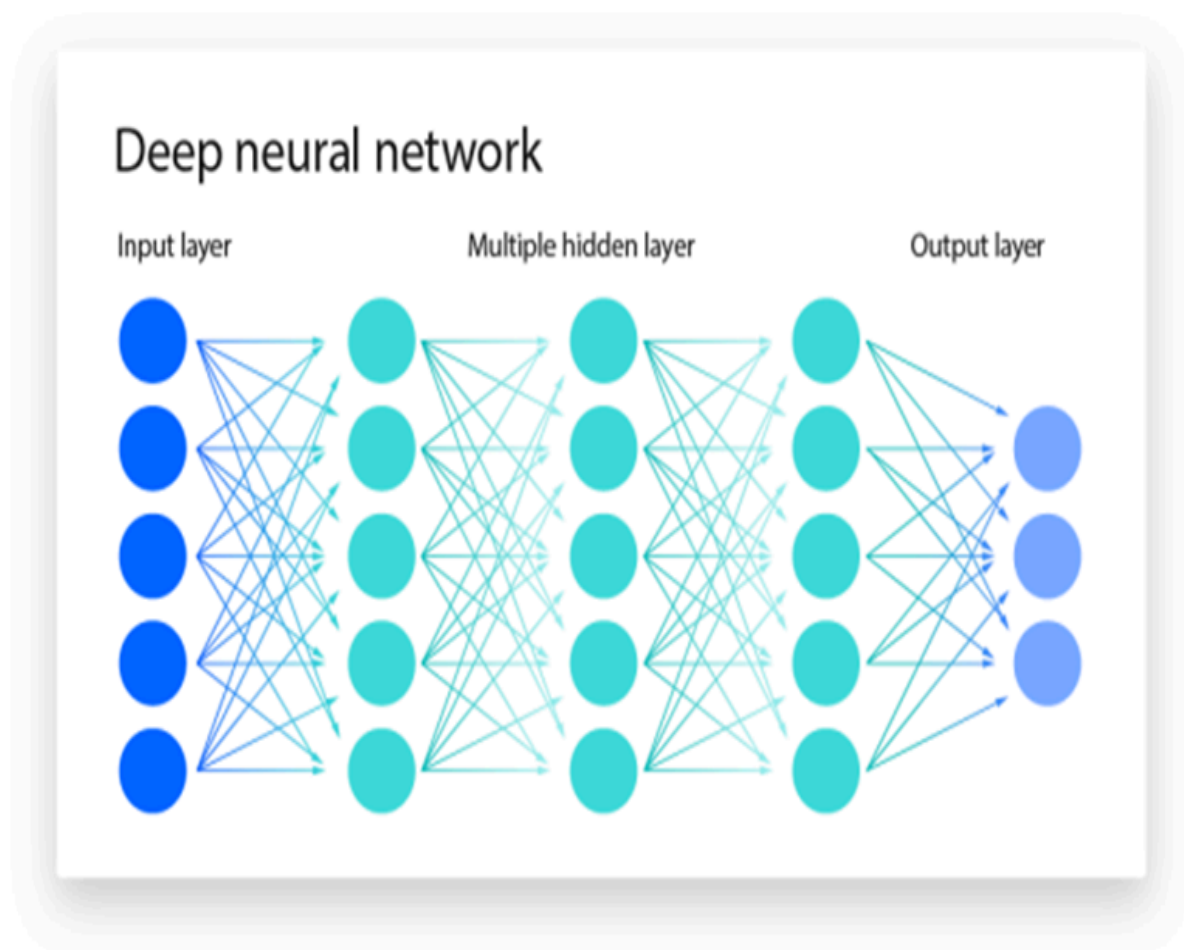
**PISHRO-NIK, Hossein.** Introduction to Probability, Statistics, and Random Processes. Sunderland: Kappa Research, Llc, 2014.

**SIQUEIRA, Ionara Santos et al.** A relação da incidência de casos de dengue com a precipitação na área urbana de Belém-PA, 2007 a 2011, através de modelos multivariados de séries temporais. 2018. Disponível em:

<https://www.scielo.br/j/rbmet/a/nzvxBYjzNXtK7CCjqjXFP6q/#>. Acesso em: 19 mar. 2025.

**SILVA, Caíque Quaresma.** Redes neurais aplicadas no reconhecimento de símbolos matemáticos manuscritos online. 2019. 54 f. Trabalho de Conclusão de Curso (Graduação em Matemática Aplicada) – Universidade de São Paulo, São Paulo, 2019. Disponível em: <https://www.ime.usp.br/~mapweb/tcc/2019/CaiqueQuaresmaV2.pdf>. Acesso em: 20 mar. 2025.

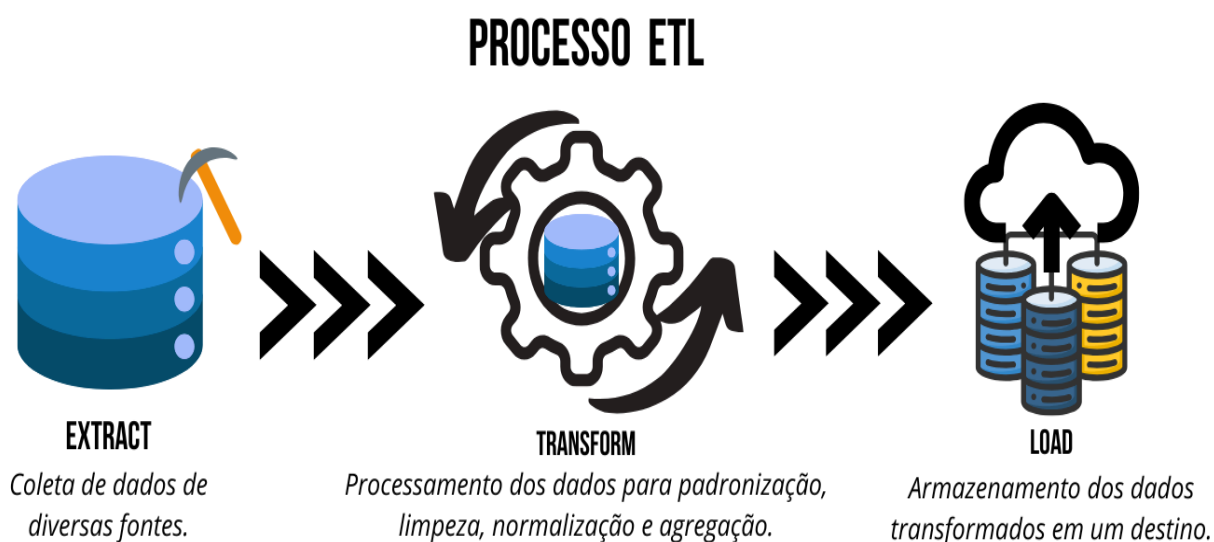
**APÊNDICE A - Rede neural MLP**  
**Figura 1 - Exemplo de rede neural MLP**



Fonte - IBM, 2025

## APÊNDICE B - Processo ETL

### Figura 2 - Exemplo de processo ETL



Fonte - Autor, 2025

## APÊNDICE C - Banco de dados

### Figura 3 - Banco de Dados da Dengue de 2013 a 2024

	id	Ano	Mes	Estado	Casos	Mortes	Temperatura	Precipitacao
1	1	2.014	Janeiro	BA	862	13	26,5	1.776,2
2	2	2.014	Janeiro	RJ	1.536	10	29	1.117,8
3	3	2.014	Janeiro	RS	18	5	27,5	6.428,6
4	4	2.014	Janeiro	SP	3.337	22.992	26,5	3.085,6
5	5	2.014	Fevereiro	BA	1.033	13	27	2.858
6	6	2.014	Fevereiro	RJ	914	17	29	882
7	7	2.014	Fevereiro	RS	33	4	27	6.636,2
8	8	2.014	Fevereiro	SP	11.698	23.464	26,5	2.540,6
9	9	2.014	Marco	BA	1.641	13	27	3.274,4
10	10	2.014	Marco	RJ	844	12	27,5	2.252,4
11	11	2.014	Marco	RS	34	3	23,5	6.796
12	12	2.014	Marco	SP	36.885	22.283	24	3.154,4

Fonte - Autor, 2025



## APÊNDICE D - Fluxo das Etapas

### Figura 4 - Fluxo das Etapas do Código



Fonte - Autor, 2025

## APÊNDICE E - Processo ETL

### Figura 6 - Parte do arquivo CSV contendo as previsões mensais por estado para 2024

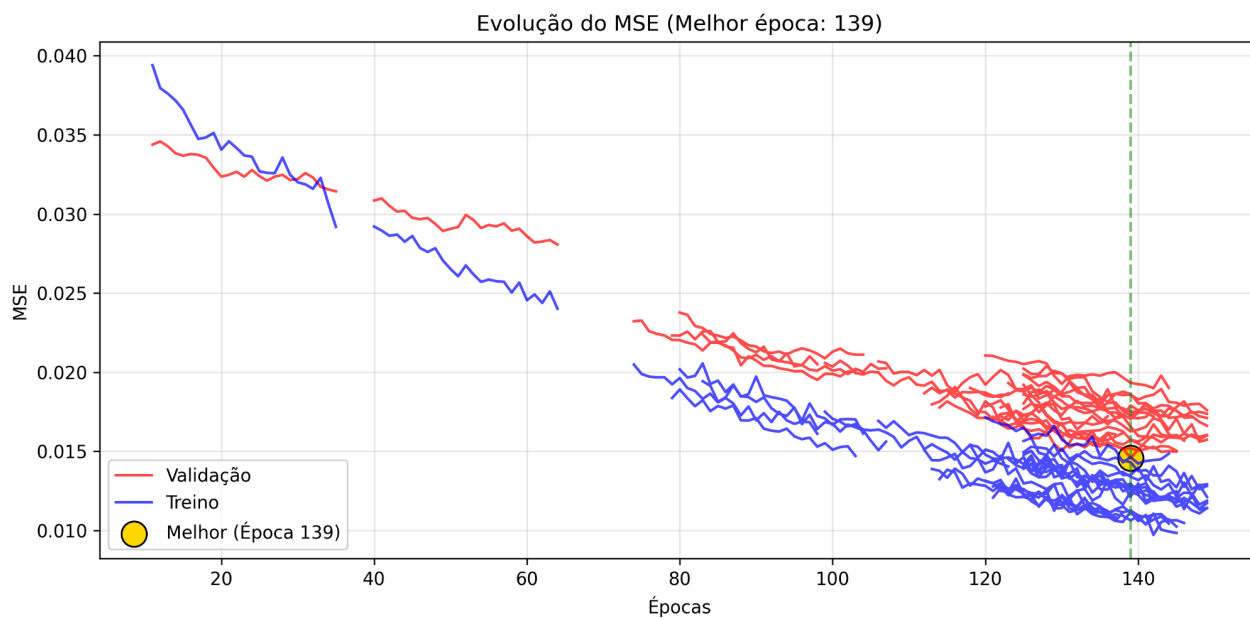
```

1 Ano,Mes,Estado,Casos_Previstos,Mortes_Previstas,timestamp
2 2024,Abril,BA,4460,2498,2025-05-16 21:02:02.729739
3 2024,Agosto,BA,4348,262,2025-05-16 21:02:02.729739
4 2024,Dezembro,BA,5411,2120,2025-05-16 21:02:02.729739
5 2024,Fevereiro,BA,1678,441,2025-05-16 21:02:02.729739
6 2024,Janeiro,BA,8309,677,2025-05-16 21:02:02.729739
7 2024,Julho,BA,1984,2617,2025-05-16 21:02:02.729739
8 2024,Junho,BA,4950,1474,2025-05-16 21:02:02.729739
9 2024,Maio,BA,5618,2845,2025-05-16 21:02:02.729739
10 2024,Marco,BA,1706,2032,2025-05-16 21:02:02.729739
11 2024,Novembro,BA,5637,-945,2025-05-16 21:02:02.729739
12 2024,Outubro,BA,1372,1045,2025-05-16 21:02:02.729739
13 2024,Setembro,BA,-3037,1617,2025-05-16 21:02:02.729739
14 2024,Abril,RJ,-5827,1592,2025-05-16 21:02:02.729739
  
```

Fonte - Autor, 2025

## APÊNDICE F - Evolução de perda

**Figura 7** - Evolução da função de perda (MSE - Erro Quadrático Médio)



Fonte - Autor, 2025